

Kiến trúc SOA & Microservices

Đặng Ngọc Hùng

Mục lục

8. Cổng API — API Gateway & BFF Pattern	4
8.1. Động lực sử dụng API Gateway	5
8.1.1. Vấn đề: client giao tiếp trực tiếp với nhiều services	5
8.1.2. API Gateway pattern	6
8.1.3. API Gateway vs BFF (Backend for Frontend)	6
8.2. Spring Cloud Gateway — Reactive Gateway	8
8.2.1. Vấn đề: chọn công nghệ cho gateway	8
8.2.2. Kiến trúc Spring Cloud Gateway	8
8.3. Cấu hình route với Eureka	9
8.3.1. Vấn đề: route cố định (hardcoded) hay động (dynamic)?	9
8.3.2. Cấu hình route cho LMS Gateway	9
8.3.3. Cách <code>lb://</code> hoạt động	10
8.4. Cross-Cutting Concerns tại Gateway	11
8.4.1. Vấn đề: mỗi service triển khai authentication, CORS và logging theo cách khác nhau	11
8.4.2. Xác thực — kiểm tra JWT tại Gateway	11
8.4.3. CORS — Cross-Origin Resource Sharing	13
8.4.4. Rate Limiting	14
8.4.5. Logging & Tracing	17
8.5. Case Study: KBM	17
8.5.1. Kiến trúc tổng thể	17
8.5.2. Phân tích cấu hình	18
8.5.3. Vấn đề không đồng nhất phiên bản JWT	19
8.5.4. Đề xuất migration	19
8.6. Tổng kết	21
8.7. Đọc thêm	21
Tài liệu tham khảo	22

8.

CHƯƠNG 8.

Cổng API — API Gateway & BFF Pattern

“The API Gateway is the single entry point for all clients. It handles cross-cutting concerns so that individual services don’t have to.”

— Chris Richardson, *Microservices Patterns* [2a]

MỤC TIÊU HỌC TẬP


- Hiểu tại sao microservices cần API Gateway và các vấn đề nó giải quyết
- Nắm vững API Gateway pattern và Backend for Frontend (BFF) pattern
- Sử dụng Spring Cloud Gateway (WebFlux) để triển khai gateway
- Cấu hình route với Eureka service discovery (load-balanced URIs)
- Thiết kế cross-cutting concerns tại gateway: authentication, CORS, rate limiting
- Phân tích kiến trúc gateway trong KBM

8.1. Động lực sử dụng API Gateway

Trong một khuôn viên trường đại học rộng lớn, nếu không có một cổng thông tin duy nhất, việc tìm kiếm và truy cập các dịch vụ sẽ trở nên vô cùng rối rắm. Hệ thống microservices cũng đối mặt với một thách thức tương tự ở phía client.

8.1.1. Vấn đề: client giao tiếp trực tiếp với nhiều services

Khi không có gateway, client (web, mobile) phải biết địa chỉ của *từng* microservice và gọi trực tiếp. Với KBM gồm nhiều services và module lab, mỗi trang web có thể cần gọi nhiều API khác nhau:



Hình 8.1: Không có Gateway — client phải biết địa chỉ của từng service

Việc bắt client (đặc biệt là giao diện người dùng) phải tự ghi nhớ và gọi đến từng service riêng lẻ chẳng khác nào yêu cầu tân sinh viên tự cầm bản đồ đi tìm từng phòng ban để hoàn tất thủ tục nhập học thay vì chỉ đến bộ phận “Một cửa” duy nhất.

🔗 Cổng bảo vệ trường Đại học

Hãy tưởng tượng hệ thống Microservices như một khuôn viên trường đại học với hàng chục tòa nhà (Khoa CNTT, Thư viện, Ký túc xá). Nếu không có cổng chính (API Gateway), một khách mời sẽ phải tự cầm bản đồ, tự tìm kiếm và di chuyển đến từng tòa nhà, gõ cửa hỏi đường, và tòa nhà nào cũng phải bố trí bảo vệ riêng để kiểm tra thẻ. **API Gateway** hoạt động như Bộ phận một cửa của trường đại học. Sinh viên chỉ cần đến một địa chỉ duy nhất (một URL), nhân viên trực sẽ kiểm tra thẻ sinh viên (Authentication) và chuyển yêu cầu đến đúng phòng ban chức năng (Routing). Tuy nhiên, phòng ban đích vẫn phải kiểm tra con dấu hoặc giấy giới thiệu theo mức độ rủi ro, rồi tự quyết định sinh viên có quyền thực hiện nghiệp vụ cụ thể hay không (Authorization).

Richardson trong [2a, Ch.8] chỉ ra năm vấn đề khi để ứng dụng client gọi trực tiếp đến từng microservice:

1. **Nhiều endpoints:** Client phải quản lý và ghi nhớ URL của mọi dịch vụ riêng lẻ, dẫn đến sự liên kết chặt chẽ (tight coupling) giữa frontend và backend.
2. **Giao thức khác nhau:** Các dịch vụ có thể sử dụng đa dạng giao thức (REST, gRPC, WebSocket), buộc frontend phải trang bị nhiều thư viện hỗ trợ tương ứng, làm tăng độ phức tạp của mã nguồn.
3. **Cross-cutting concerns phân tán:** Mỗi dịch vụ phải tự triển khai các nghiệp vụ cắt ngang như xác thực, CORS, và rate limiting, gây ra sự trùng lặp và nguy cơ bất nhất quán trong các chính sách hệ thống.
4. **Network không an toàn:** Việc phơi bày trực tiếp toàn bộ các API endpoint nội bộ ra môi trường Internet làm gia tăng bề mặt tấn công (attack surface), tạo cơ hội cho các rủi ro bảo mật tiềm ẩn.

5. **API không phù hợp:** Các giao diện lập trình nội bộ thường được thiết kế cho quá trình tương tác giữa máy chủ với máy chủ, trả về lượng dữ liệu dư thừa hoặc yêu cầu quá nhiều vòng gọi mạng (calls), gây nghẽn cổ chai đối với các nền tảng di động có băng thông hạn hẹp.

8.1.2. API Gateway pattern

API Gateway là **điểm vào duy nhất** (single entry point) — toàn bộ yêu cầu (request) từ ứng dụng khách sẽ đi qua Gateway và được định tuyến (route) đến đúng dịch vụ tương ứng:



Hình 8.2: API Gateway — single entry point route đến từng service

Gateway xử lý các nghiệp vụ cắt ngang (**cross-cutting concerns**) một cách tập trung, bao gồm: xác thực ở biên (edge authentication), CORS, giới hạn lưu lượng (rate limiting), logging và kết thúc SSL (SSL termination). Các dịch vụ phía sau không cần lặp lại CORS hay rate limiting, nhưng vẫn phải xác minh bằng chứng danh tính theo tầng tin cậy (trust tier) và thực hiện authorization cục bộ cho tài nguyên mình sở hữu.

Gateway thường được ví như một “smart edge” (điểm biên thông minh) chuyên xử lý các cross-cutting concerns. Tuy nhiên, theo đúng tinh thần của nguyên lý “**Smart endpoints and dumb pipes**” do James Lewis và Martin Fowler nêu ra (2014), Gateway không nên chứa business logic. Đối với dữ liệu nghiệp vụ, Gateway vẫn phải duy trì vai trò của một “dumb pipe” (chỉ định tuyến cơ bản) để tránh lặp lại vấn đề của ESB.

8.1.3. API Gateway vs BFF (Backend for Frontend)

Richardson trong [2a, Ch.8] phân biệt hai biến thể:



Hình 8.3: API Gateway (một gateway chung) vs BFF (gateway riêng cho từng client)

Richardson phân biệt hai biến thể chính của Gateway. Biến thể phổ thông nhất là **API Gateway**, nơi một cổng duy nhất phục vụ toàn bộ các loại client. Phương pháp này đặc biệt phù hợp với các đội ngũ nhỏ hoặc khi các ứng dụng client (như web admin và web sinh viên) có nhu cầu truy xuất dữ liệu tương đồng nhau. Tuy nhiên, khi hệ thống mở rộng, biến thể **BFF (Backend for Frontend)** lại tỏ ra phù hợp hơn trong kịch bản này bằng cách cung cấp một Gateway chuyên biệt cho từng loại client. BFF là giải pháp bắt buộc khi ứng dụng di động (mobile app) đòi hỏi định dạng API hoàn toàn khác biệt so với nền tảng web, ví dụ như cần gộp nhiều lời gọi (batched calls) và tối giản hóa dữ liệu trả về để tiết kiệm băng thông. KBM sử dụng **một API Gateway duy nhất** cho phân hệ lõi của LMS — điều này hoàn toàn phù hợp vì các web frontend chính đều có chung những yêu cầu API tương tự nhau. Với DevOps Lab, KBM bổ sung một lớp router riêng theo hostname để điều hướng workspace/lab runtime; đây là gateway chuyên biệt cho một bounded context, không thay thế Spring Cloud Gateway của LMS core.

Khi nào cần BFF? BFF trở nên cần thiết khi các client khác nhau có nhu cầu API hoàn toàn khác biệt về bản chất — không chỉ đơn thuần là “lọc bỏ bớt các trường dữ liệu”:

Quyết định áp dụng BFF có thể dựa trên ba kịch bản thực tế.

Nếu hệ thống chỉ phục vụ Web và Web Admin với nhu cầu dữ liệu tương tự nhau, một **Single Gateway** là đủ — áp dụng BFF lúc này chỉ gây dư thừa kỹ thuật (over-engineering).

Khi có thêm ứng dụng di động, Single Gateway buộc client mobile gọi nhiều API rồi rạc chỉ để dựng một màn hình; một Mobile BFF chuyên gom dữ liệu (aggregate) sẽ cắt đáng kể số vòng gọi mạng.

Ở kịch bản phức tạp nhất — thêm thiết bị IoT (như hệ thống điểm danh khuôn mặt ở giảng đường) và đối tác thứ ba (như cổng thanh toán học phí của ngân hàng) — một cổng duy nhất sẽ phình to, khó bảo trì; đây là lúc bắt buộc chia thành **nhiều BFF độc lập** phục vụ riêng từng nhóm client.

Ví dụ: nếu KBM phát triển thêm **mobile app** cho sinh viên, nền tảng này sẽ yêu cầu: (1) **batched API** — giao diện “Bảng điều khiển” (Dashboard) chỉ cần một lời gọi để lấy cả thông tin cá nhân, bài nộp gần đây và thứ hạng (thay vì phải gọi ba lần, giúp khắc phục hạn chế mạng di động chậm); (2) **reduced payload** — thiết bị di động không cần dữ liệu định dạng sẵn cho HTML mà chỉ cần dữ liệu thô gọn nhẹ; (3) **tích hợp thông báo đẩy (push notification)** — Gateway dành riêng cho di động sẽ quản lý các mã định danh thiết bị (device tokens).

Newman trong [4a, Ch.4] khuyến nghị: BFF nên được **quản lý bởi đội ngũ phát triển giao diện (frontend)** — đội ngũ phát triển ứng dụng di động chịu trách nhiệm về Mobile BFF, đội ngũ phát triển web đảm nhận Web BFF. Mỗi BFF hoạt động như một lớp xử lý mỏng (thin layer): tiếp nhận yêu cầu từ

ứng dụng khách, gọi các dịch vụ nội bộ (downstream services), tiến hành gom nhóm và biến đổi dữ liệu (aggregate và transform), sau đó trả về định dạng phù hợp cho từng loại ứng dụng khách.

⚠ Aggregation vs Orchestration

BFF được phép thực hiện **Data Aggregation** (gom nhiều lời gọi API lại để giao diện người dùng (UI) hiển thị nhanh hơn). Tuy nhiên, cần đặc biệt tránh việc sử dụng BFF hay Gateway để thực hiện **Business Orchestration** (điều phối nghiệp vụ, ví dụ: tạo bài nộp (Submission) rồi cập nhật điểm số (Grade)). Mọi logic điều phối giao dịch phải nằm ở tầng Domain Services (sử dụng Saga/Process Manager như ở Chương 6).

8.2. Spring Cloud Gateway – Reactive Gateway

Khi xây dựng API Gateway, việc lựa chọn công nghệ lõi quyết định khả năng mở rộng và chịu tải của hệ thống. Bài toán đặt ra là cần một kiến trúc đáp ứng được lưu lượng kết nối lớn.

8.2.1. Vấn đề: chọn công nghệ cho gateway

Trong hệ sinh thái Spring, các nhà phát triển thường cân nhắc giữa hai lựa chọn chính khi xây dựng Gateway tập trung:

Mô hình hoạt động – Spring Cloud Gateway sử dụng mô hình phản ứng (Reactive - WebFlux, non-blocking), cho phép xử lý số lượng lớn các kết nối đồng thời với rất ít luồng (threads). Trong khi đó, Netflix Zuul (phiên bản 1.x) dựa trên mô hình Servlet truyền thống (blocking, thread-per-request), dễ bị thắt cổ chai khi đối mặt với tải trọng lớn.

Hiệu năng và WebSocket – Nhờ kiến trúc WebFlux, Spring Cloud Gateway mang lại hiệu năng cao hơn và hỗ trợ giao thức WebSocket một cách tự nhiên (native support) – một tính năng cốt lõi cho các ứng dụng hệ thống thời gian thực. Ngược lại, Zuul 1.x có hiệu suất thấp hơn do phụ thuộc vào giới hạn của nhóm luồng (thread pool) và hoàn toàn không hỗ trợ WebSocket.

Hệ sinh thái và Tình trạng – Spring Cloud Gateway hiện là dự án đang được tích cực phát triển (active), được Spring chính thức khuyến dùng và gắn kết chặt chẽ vào hệ sinh thái Spring Cloud. Trái lại, Netflix Zuul 1.x đã bị đánh dấu lỗi thời (deprecated) do Netflix ngừng bảo trì và hiện chỉ được xem như một hệ thống công nghệ cũ (legacy).

Dựa trên các ưu điểm này, kiến trúc cốt lõi của LMS sử dụng **Spring Cloud Gateway**. Quyết định này nhằm đáp ứng yêu cầu hỗ trợ giao thức WebSocket cho tính năng đẩy thông báo (notification push) liên tục, đồng thời đảm bảo hiệu năng cao cho hệ thống.

8.2.2. Kiến trúc Spring Cloud Gateway

Khác với các gateway nguyên khối thế hệ trước, Spring Cloud Gateway chia quá trình xử lý request thành những thành phần độc lập và dễ kết hợp. 8.4 minh họa luồng đi của một request: nó lần lượt được đối chiếu với các **Predicates** (điều kiện định tuyến) và đi qua chuỗi **Filters** (bộ lọc) trước khi được chuyển tới service đích.



Hình 8.4: Kiến trúc Spring Cloud Gateway — Predicates, Filters, Routes

Kiến trúc của Spring Cloud Gateway xoay quanh ba khái niệm cốt lõi:

Route – Quy tắc định tuyến từ một điều kiện đầu vào đến URI đích — ví dụ chuyển toàn bộ `/api/core/**` sang `lb://kbm-core`.

Predicate – Phép thử boolean quyết định request có khớp Route hay không, dựa trên các thuộc tính như `Path` hay `Method`.

Filter – Điểm can thiệp vào vòng đời request/response, chạy trước hoặc sau bước định tuyến để xử lý các nghiệp vụ cắt ngang — xác thực qua `JwtRequestFilter`, gắn thêm header, ghi log.

Về **dependency**: Gateway sử dụng thư viện `spring-cloud-starter-gateway` (WebFlux) và `spring-cloud-starter-netflix-eureka-client`. **Lưu ý**: Do Gateway hoạt động dựa trên cơ chế WebFlux (mô hình phản ứng, không chặn luồng), nó *không thể* tương thích với `spring-boot-starter-web` (mô hình servlet, chặn luồng). Việc khai báo đồng thời cả hai thư viện này trong dự án Gateway sẽ sinh ra xung đột (conflict) và khiến ứng dụng không thể khởi động.

8.3. Cấu hình route với Eureka

Khác với các phòng ban cố định trong trường học, các máy chủ dịch vụ ảo có thể thay đổi địa chỉ liên tục. Việc định tuyến cố định sẽ bộc lộ nhiều hạn chế khi hệ thống bắt đầu tự động thay đổi quy mô.

8.3.1. Vấn đề: route cố định (hardcoded) hay động (dynamic)?

Phương pháp đơn giản nhất là gán cố định (hardcode) địa chỉ URL cho từng dịch vụ trong tệp cấu hình của Gateway. Tuy nhiên, khi các dịch vụ mở rộng quy mô (scale) hoặc được triển khai (deploy) sang container mới, các địa chỉ URL sẽ thay đổi. Khi đó, việc cập nhật thủ công cấu hình Gateway sẽ trở nên khó khăn và tiềm ẩn nhiều rủi ro phát sinh lỗi.

Giải pháp: kết hợp Gateway routing với **Eureka service discovery** (đã học ở Ch.4). Gateway không cần lưu trữ địa chỉ IP và cổng cụ thể của dịch vụ — nó chỉ cần tên dịch vụ: Eureka cung cấp danh sách instance đang sống, Spring Cloud LoadBalancer chọn một instance trong danh sách đó, và Gateway chuyển tiếp request tới đích đã chọn.

8.3.2. Cấu hình route cho LMS Gateway

```

# application-lb.yml — LMS Gateway routing configuration
spring:
  cloud:
    gateway:
      routes:

```

```

# Core Service — questions, submissions, contests
- id: kbm-core
uri: lb://kbm-core      # lb:// = Eureka lookup + load balance
predicates:
  - Path=/api/core/**
filters:
  - StripPrefix=2      # /api/core/questions → /questions

# Assignment Service — courses, grades
- id: kbm-academic
uri: lb://kbm-academic
predicates:
  - Path=/api/assignment/**
filters:
  - StripPrefix=2

# Auth Service — login, register
- id: kbm-auth
uri: lb://kbm-auth
predicates:
  - Path=/api/auth/**
filters:
  - StripPrefix=2


# Notification — WebSocket endpoint
- id: kbm-notification-ws
uri: lb://kbm-notification
predicates:
  - Path=/ws/**

```

Listing 8.1: Cấu hình route của LMS Gateway (YAML + Eureka)

8.3.3. Cách `lb://` hoạt động

8.5 minh họa luồng phân giải chuỗi URI với tiền tố `lb://` trong thực tế, khi một request định tuyến đến một dịch vụ ảo thông qua Eureka thay vì IP tĩnh:

Hình 8.5: Luồng `lb://` — Eureka lookup + load balance + route

`lb://kbm-core` thực hiện ba bước tự động:

1. **Lookup:** truy vấn (query) Eureka để lấy danh sách toàn bộ instance đang đăng ký dưới tên `kbm-core`
2. **Load balance:** lựa chọn một thực thể thông qua Spring Cloud LoadBalancer (round-robin mặc định)

3. **Forward**: chuyển tiếp yêu cầu (request) đến thực thể đã được chọn

`StripPrefix=2` loại bỏ 2 phần đầu tiên của path: `/api/core/questions` → `/questions`. Nhờ đó, dịch vụ không cần quan tâm đến đường dẫn gốc (mount path) của nó tại Gateway — dịch vụ chỉ cần xử lý đường dẫn nội bộ của chính nó.

Service không biết Gateway

Các dịch vụ phía sau *không nên biết* về sự tồn tại của Gateway. Mỗi dịch vụ tự xử lý (handle) các đường dẫn nội bộ tương ứng (`/questions`, `/users`), trong khi Gateway đảm nhiệm việc gắn tiền tố (prefix) và định tuyến. Điều này đảm bảo: (1) Các dịch vụ có thể được kiểm thử độc lập (standalone) mà không phụ thuộc vào Gateway; (2) Việc cấu trúc lại định tuyến tại Gateway không làm ảnh hưởng đến mã nguồn của dịch vụ; (3) Dịch vụ có tính di động cao (portable) — cho phép dễ dàng triển khai (deploy) sau các gateway khác (như NGINX, Kong) mà không cần chỉnh sửa mã nguồn.

8.4. Cross-Cutting Concerns tại Gateway

Triển khai các nghiệp vụ cắt ngang ở mỗi dịch vụ giống như từng lớp học tự đặt ra quy định kiểm tra thẻ sinh viên riêng lẻ thay vì giao cho bảo vệ cổng trường: vừa dư thừa, vừa không thống nhất và khó quản lý.

8.4.1. Vấn đề: mỗi service triển khai authentication, CORS và logging theo cách khác nhau

Nếu mỗi dịch vụ tự viết một bộ phân tích JWT, tự cấu hình CORS và tự triển khai rate limiting theo cách riêng, mã nguồn sẽ bị trùng lặp và chính sách dễ trôi dạt. Gateway giải quyết phần chính sách ở biên: tiếp nhận thông tin xác thực (credential) từ client, loại bỏ dữ liệu định danh có thể giả mạo, kiểm tra token và áp dụng các biện pháp bảo vệ lưu lượng. Điều đó không xóa trách nhiệm của resource service: service đích vẫn xác minh bằng chứng đã ký theo hợp đồng chung và tự thực hiện authorization nghiệp vụ.

8.4.2. Xác thực — kiểm tra JWT tại Gateway

Hạn chế của Session Cookie

Trong Monolith, trường đại học chỉ có một cô Thủ thư duy nhất. Khi một sinh viên vào thư viện, cô nhận ra mặt và nhớ đó là sinh viên (Session Cookie). Nhưng khi trường mở rộng ra 10 chi nhánh thư viện (Microservices), sinh viên sang chi nhánh khác, cô thủ thư mới sẽ không biết người đó là ai. Sinh viên bắt buộc phải dùng chung một sổ đăng ký trung tâm (Shared Redis) gây nghẽn thắt cổ chai. Đó là lý do chúng ta chuyển sang **JWT (JSON Web Token)** — hãy coi nó như **thẻ sinh viên điện tử**. Trên thẻ JWT đã dán ảnh, ghi mã SV, và có “con dấu đỏ” chữ ký điện tử của phòng Đào tạo. Các tòa nhà (Downstream services) hoặc cổng bảo vệ (Gateway) chỉ cần nhìn con dấu là biết thẻ thật, hoàn toàn không cần gọi điện hỏi lại phòng Đào tạo (Stateless Validation).

Do hạn chế của Session Cookie trong kiến trúc phân tán, KBM lựa chọn cơ chế xác thực không trạng thái (stateless) với JSON Web Token (JWT). Gateway là chốt kiểm tra đầu tiên, nhưng không phải bằng chứng duy nhất cho mọi trust boundary. Đoạn mã dưới đây mô tả **hiện trạng chuyên tiếp** của `JwtAuthGlobalFilter`: loại bỏ các header định danh do client tự khai, xác minh access token tại biên và gửi lại `Authorization` để các service đang xác minh token không bị mất bằng chứng trước khi cơ chế token nội bộ có chữ ký được triển khai:

```
// Gateway JWT Filter — validate token trước khi route
@Component
```

```

public class JwtAuthGlobalFilter implements GlobalFilter, Ordered {

    private final JwtUtil jwtUtil;

    @Override
    public Mono<Void> filter(ServerWebExchange exchange, GatewayFilterChain chain) {
        ServerHttpRequest request = exchange.getRequest();
        String path = request.getURI().getPath();

        // Bắt buộc XÓA identity headers do client tự gửi (chống Header Spoofing).
        // KHÔNG xóa Authorization trước khi có signed downstream token thay thế.
        ServerHttpRequest.Builder requestBuilder = request.mutate()
            .headers(headers -> {
                headers.remove("X-User-Id");
                headers.remove("X-User-Roles");
            });

        // Bỏ qua xác thực cho các endpoint công khai
        if (isPublicEndpoint(path)) {
            return chain.filter(
                exchange.mutate().request(requestBuilder.build()).build()
            );
        }

        // Xác minh alg + signature + iss + aud + exp + nbf cho audience của Gateway
        String token = extractToken(request);
        if (token == null || !jwtUtil.validateAccessToken(token, "kbm-gateway")) {
            exchange.getResponse().setStatusCode(HttpStatus.UNAUTHORIZED);
            return exchange.getResponse().setComplete();
        }

        // Context dẫn xuất: chỉ dùng cho routing/rate limit.
        // Giữ Authorization cho downstream verifier.
        requestBuilder.headers(headers -> {
            headers.set("X-User-Id", jwtUtil.getUserId(token));
            headers.set("X-User-Roles", jwtUtil.getRoles(token));
        });


        return chain.filter(
            exchange.mutate().request(requestBuilder.build()).build()
        );
    }

    @Override
    public int getOrder() {
        return -1; // Chạy TRƯỚC RequestRateLimiter
    }
}

```

Listing 8.2: Global JWT Filter bảo mật tại Gateway

Sau khi Gateway xác thực JWT, thông tin định danh (claims) cần được truyền đến các dịch vụ phía sau (downstream) mà không biến một header thuần thành bằng chứng danh tính. 8.6 mô tả luồng chuyển tiếp: token đã ký được giữ lại hoặc được đổi thành token nội bộ đúng audience; các header dẫn xuất chỉ là context tiện dụng cho routing, logging và rate limiting:



Hình 8.6: Luồng JWT tại Gateway — bằng chứng có chữ ký và context định danh dẫn xuất

Trong **hiện trạng KBM**, Gateway chèn **X-User-Id** và **X-User-Roles**; một số service tin các header này, trong khi một số service khác vẫn tự parse JWT bằng thư viện và phiên bản khác nhau. Đây là sự trôi lệch triển khai (implementation drift), không phải phòng thủ chiều sâu (defense in depth) có chủ đích. Plain-header trust chỉ được ghi nhận là **rủi ro được chấp nhận** (accepted risk) tạm thời khi service không thể bị truy cập ngoài đường đi đã kiểm soát; nó không phải kiến trúc mục tiêu.

Ở **mục tiêu Tier 1**, Gateway xác minh token ngoài rồi chuyển tiếp bằng chứng có chữ ký — giữ access token trong giai đoạn chuyển tiếp hoặc token exchange sang internal token đúng audience. Resource service xác minh issuer, audience, signature và freshness trước khi dùng claims, sau đó tự kiểm tra authorization nghiệp vụ. **X-User-*** có thể tồn tại như dữ liệu dẫn xuất, nhưng không được dùng một mình để ra quyết định cấp quyền.

⚠ Giả định tin cậy mạng

Network policy (firewall rules, Kubernetes NetworkPolicy) phải chặn truy cập trực tiếp vào service, còn Gateway phải loại bỏ mọi **X-User-*** từ Internet trước khi tự ghi đè context đã dẫn xuất. Đây là điều kiện tối thiểu cho accepted risk hiện tại, nhưng chỉ chứng minh *đường đi của request*, không chứng minh nội dung claims.

Cần nhớ giới hạn của mTLS: nó bảo vệ kênh truyền và chứng thực *workload/actor* ở hai đầu, không chứng thực *user subject* trong **X-User-Id**. Một workload nội bộ bị chiếm quyền vẫn có thể tạo header giả. Vì vậy, request nhảy cảm cần đồng thời có signed identity proof đúng audience, local authorization và — nếu service gọi thay mặt người dùng — ngữ nghĩa delegation tách biệt subject khỏi actor.

8.4.3. CORS — Cross-Origin Resource Sharing

Cấu hình CORS tại Gateway là **một nơi duy nhất** quản lý các origin, method và header được chấp nhận. Cấu hình **globalcors** trong Spring Cloud Gateway cho phép khai báo **allowedOrigins** (các tên miền hợp lệ),

`allowedMethods` , `allowCredentials` — các dịch vụ phía sau không cần thiết lập cấu hình CORS vì Gateway đã đảm nhận chức năng này.

```
spring:
  cloud:
    gateway:
      globalcors:
        cors-configurations:
          '[/*]':
            allowed-origins:
              - "https://kbm.example.edu"
              - "https://admin.kbm.example.edu"
            allowed-methods: "GET, POST, PUT, DELETE, OPTIONS"
            allowed-headers:      # BẮT BUỘC — thiếu dòng này thì allowedHeaders = null
              - "Authorization"  # → checkHeaders() trả null → preflight bị từ chối
              - "Content-Type"   # → mọi API cross-origin kèm JWT chết ngay
              - "X-Correlation-Id"
            allow-credentials: true # chỉ cần khi xác thực bằng cookie; với Bearer header có thể để false
```

Listing 8.3: Cấu hình CORS an toàn tại Gateway

Cấu hình CORS ở cấp độ Gateway giúp hệ thống tránh phải thiết lập lại các quy tắc tương tự ở từng dịch vụ. Bằng cách khai báo tập trung các origin hợp lệ (`allowedOrigins`), method được phép (`allowedMethods`), danh sách header được chấp nhận (`allowedHeaders`) và việc có cho phép gửi kèm credential hay không (`allowCredentials`), Gateway kiểm soát các yêu cầu cross-origin một cách nhất quán. **Lưu ý quan trọng:** Spring Cloud Gateway *không* tự động cho phép mọi header khi khai báo `globalcors` qua YAML — nếu thiếu `allowed-headers` , `CorsConfiguration.checkHeaders()` sẽ trả về `null` (từ chối), khiến mọi preflight request chứa `Authorization` thất bại và toàn bộ lời gọi API cross-origin kèm JWT chết ngay ở bước OPTIONS.

KBM CORS

Hệ thống KBM từng sử dụng cấu hình `allowedOrigins: "*"` — cho phép *mọi* nguồn gốc (origin) truy xuất API. Trong giai đoạn phát triển (development), đây là giải pháp tiện lợi để tránh lỗi CORS. Tuy nhiên, trên môi trường thực tế (production), đây là một chính sách **quá rộng** so với chủ đích của KBM (API không nhằm phục vụ public cross-origin): mọi trang web đều có thể gọi và *đọc* phản hồi không kèm credentials. Cần tách bạch hai điều thường bị nhầm: (1) với chế độ gửi kèm credentials, trình duyệt *từ chối* tổ hợp `* + allowCredentials: true` — muốn cookie hoạt động xuyên origin bắt buộc phải allowlist origin cụ thể; (2) CORS chỉ kiểm soát việc JavaScript *đọc* response, nó **không phải** cơ chế chống CSRF — xác thực dựa trên cookie vẫn cần `SameSite` , CSRF token hoặc kiểm tra Origin riêng (Ch.9). **Migration:** (1) Lập allowlist nguồn gốc riêng cho từng môi trường — sách không công bố domain thật của hệ thống; (2) chỉ bật `allowCredentials: true` khi dùng xác thực cookie và đã áp dụng các biện pháp chống CSRF nói trên; (3) kiểm thử riêng với ứng dụng di động, nếu có.

8.4.4. Rate Limiting

Cơ chế giới hạn lưu lượng (Rate limiting) là kỹ thuật để ngăn chặn tình trạng một client gửi quá nhiều yêu cầu trong thời gian ngắn, qua đó bảo vệ các dịch vụ cốt lõi khỏi nguy cơ quá tải hoặc bị tấn công từ chối dịch vụ (DoS). Spring Cloud Gateway hỗ trợ sẵn bộ lọc `RequestRateLimiter` kết hợp với Redis để hiện thực hóa tính năng này. Bằng cách tùy chỉnh các thông số như tỷ lệ phục hồi `replenishRate` (số yêu cầu mỗi giây), dung lượng bù đắp `burstCapacity` (số lượng yêu cầu tối đa xử lý tức thời), và thành phần xác định

khóa `KeyResolver`, hệ thống có thể kiểm soát lưu lượng truy cập dựa trên nhiều chính sách khác nhau. Các chiến lược phổ biến bao gồm:

1. **Theo người dùng (per user):** Áp dụng hạn ngạch (ví dụ: N requests/giây) cho từng người dùng đã xác thực. Phương pháp này giúp ngăn chặn lạm dụng hoặc khai thác tài nguyên quá mức từ một tài khoản.
2. **Theo IP (per IP):** Giới hạn lưu lượng từ một địa chỉ IP duy nhất. Chiến lược này hiệu quả trong việc ngăn chặn tấn công DDoS thô sơ hoặc ngăn chặn các bot cào dữ liệu (scraping).
3. **Theo route (per route):** Thiết lập giới hạn riêng cho từng API. Kỹ thuật này thường áp dụng để bảo vệ các API tiêu tốn nhiều năng lực tính toán hoặc I/O (ví dụ: xuất báo cáo thống kê).
4. **Toàn cục (global):** Giới hạn tổng lượng yêu cầu truy cập đi vào hệ thống từ mọi nguồn. Quy tắc này hoạt động như chiếc cầu chì an toàn cuối cùng, bảo đảm hạ tầng mạng bên trong không bị quá tải khi đối mặt với lưu lượng đột biến.

Triển khai rate limiting với Redis:

Spring Cloud Gateway sử dụng **thuật toán Token Bucket** (Redis-backed) — mỗi người dùng sở hữu một “bucket” chứa thẻ bài (tokens), mỗi yêu cầu tiêu thụ một thẻ bài, và các thẻ bài này được bổ sung theo tỷ lệ `replenishRate`:

```
# application.yml — Rate limiting cho endpoint chấm bài
spring:
  cloud:
    gateway:
      routes:
        - id: kbm-core-rate-limited
          uri: lb://kbm-core
          predicates:
            - Path=/api/core/submissions/**
          filters:
            - StripPrefix=2
            - name: RequestRateLimiter
          args:
            redis-rate-limiter.replenishRate: 5 # 5 requests/giây
            redis-rate-limiter.burstCapacity: 10 # Burst tối đa 10
            redis-rate-limiter.requestedTokens: 1 # 1 token/request
            key-resolver: "#{@userKeyResolver}" # Rate limit theo user

data:
  redis:
    host: localhost
    port: 6379
```

Listing 8.4: Cấu hình rate limiting cho endpoint nộp bài

Trong cấu hình trên, bộ lọc `RequestRateLimiter` được áp dụng vào route nộp bài tập với các thông số về tỷ lệ phục hồi và dung lượng token. Tuy nhiên, Gateway cần một `KeyResolver` để xác định định danh (khóa) cho từng yêu cầu nhằm cấp phát hạn ngạch phù hợp. Đoạn mã dưới đây triển khai `KeyResolver` dùng `X-User-Id` (do bộ lọc xác thực cung cấp), kết hợp fallback an toàn để tránh `NullPointerException` đối với các API ẩn danh:

```
@Configuration
public class RateLimitConfig {

    // Địa chỉ các proxy biên được phép ghi X-Forwarded-For.
    // Đưa ra cấu hình (application.yml) thay vì hardcoded; danh sách rỗng
    // nghĩa là không tin header nào — mặc định an toàn.
```

```

@Value("${kbm.gateway.trusted-proxies}")
private Set<String> trustedProxies = Set.of();

@Bean
public KeyResolver userKeyResolver() {
    return exchange -> {
        // Lấy userId từ header đã được JWT filter inject
        String userId = exchange.getRequest().getHeaders()
            .getFirst("X-User-Id");
        if (userId != null) {
            return Mono.just(userId); // Rate limit per user
        }
        // Fallback: rate limit per IP cho anonymous requests
        // CHÚ Ý: client tự đặt được X-Forwarded-For — chỉ tin header này khi
        // proxy biên (trusted proxy) đã ghi đè/sanitize nó, nếu không kẻ tấn công
        // đổi header để né rate limit; không có proxy tin cậy -> dùng remoteAddress
        java.net.InetSocketAddress remoteAddress = exchange.getRequest().getRemoteAddress();
        String peer = (remoteAddress != null && remoteAddress.getAddress() != null)
            ? remoteAddress.getAddress().getHostAddress() : null;

        // Chỉ đọc X-Forwarded-For khi request THỰC SỰ đến từ proxy biên đã đăng ký.
        // Thiếu điều kiện này, client tự gửi header và tự chọn key rate limit.
        String forwardedFor = exchange.getRequest().getHeaders().getFirst("X-Forwarded-For");
        if (forwardedFor != null && trustedProxies.contains(peer)) {
            // Lấy phần tử CUỐI (IP do proxy biên ghi nhận) — phần tử trái nhất
            // là dữ liệu client tự khai, kẻ tấn công đổi tùy ý để né rate limit
            String[] hops = forwardedFor.split(",");
            return Mono.just(hops[hops.length - 1].trim());
        }
        // Không có proxy tin cậy -> chỉ tin địa chỉ TCP thật, không tin header
        return Mono.just(peer != null ? peer : "anonymous");
    };
}

```

Listing 8.5: KeyResolver an toàn chống NPE — xác định rate limit theo userId

Khi người dùng vượt quá hạn ngạch (limit), Gateway tự động trả về mã lỗi **HTTP 429 Too Many Requests**, qua đó thông báo trực tiếp cho client mà không cần chuyển tiếp yêu cầu xuống các dịch vụ phía sau. Về bảo mật, **X-Forwarded-For** chỉ đáng tin khi request thực sự đi qua proxy biên đã được cấu hình ghi đè header này; khi chuỗi có nhiều hop, hãy chọn IP theo số proxy tin cậy (đếm từ phải sang) thay vì lấy phần tử trái nhất do client kiểm soát. Một lưu ý vận hành: mọi khóa dùng chung — nhánh **"anonymous"** cuối cùng, hay thực tế hơn là cả phòng máy đi ra ngoài qua một IP NAT — đều gom nhiều người dùng vào một bucket. Nếu áp chính sách cá nhân (5 req/s) cho bucket đó, hàng trăm sinh viên sau cùng một NAT sẽ chia nhau đúng 5 request mỗi giây và nhận 429 hàng loạt. Route công khai cần chính sách riêng rộng hơn, hoặc đứng ngoài lớp rate limit chặt này.

💡 Rate limit cho contest mode

Trong thời gian diễn ra kỳ thi (contest mode), tần suất nộp bài cao hơn bình thường (hàng trăm sinh viên nộp bài cùng lúc). Cần lưu ý các điểm sau: (1) Cấu hình mức rate limit cao hơn cho đường dẫn **/submissions/**** trong kỳ thi; (2) Hoặc sử dụng cơ chế **giới hạn theo từng đường dẫn (per-route rate limit)** dành riêng cho các API thi cử; (3) Sử dụng tính chất nguyên tử (atomic operations) của Redis để đảm bảo đếm chính xác ngay cả khi có lượng lớn yêu cầu đồng thời (concurrent requests).

8.4.5. Logging & Tracing

Gateway là điểm lý tưởng để gắn **correlation ID** — mã định danh duy nhất theo dõi request xuyên suốt hệ thống. Cơ chế hoạt động: **GlobalFilter** tại Gateway kiểm tra header **X-Correlation-Id**. Nếu header này chưa có, hệ thống sinh một UUID mới, gắn vào request, rồi truyền xuống toàn bộ các dịch vụ phía sau (downstream services). Nhờ đó, khi cần gỡ lỗi (debug), lập trình viên có thể truy xuất log dựa trên correlation ID để theo dõi toàn bộ quá trình (journey) của yêu cầu.

```
@Component
public class CorrelationIdFilter implements GlobalFilter, Ordered {
    @Override
    public Mono<Void> filter(
        ServerWebExchange exchange, GatewayFilterChain chain) {
        String correlationId = exchange.getRequest().getHeaders()
            .getFirst("X-Correlation-Id");

        if (correlationId == null) {
            correlationId = java.util.UUID.randomUUID().toString();
            ServerHttpRequest request = exchange.getRequest().mutate()
                .header("X-Correlation-Id", correlationId)
                .build();
            return chain.filter(
                exchange.mutate().request(request).build()
            );
        }
        return chain.filter(exchange);
    }
    @Override
    public int getOrder() { return -2; }
}
```

Listing 8.6: Correlation ID GlobalFilter

Gateway cũng là vị trí lý tưởng để ghi nhận **access log tập trung**, bao gồm: method, đường dẫn (path), mã trạng thái, độ trễ (latency) và định danh người dùng (từ JWT claims). Thông tin này giúp hệ thống dễ dàng phát hiện endpoint nào có độ trễ bất thường, người dùng nào thường xuyên gặp lỗi, và sự thay đổi của mẫu lưu lượng (traffic pattern) trước và sau khi deploy. Giải pháp này giúp loại bỏ yêu cầu chèn thêm mã nguồn vào từng dịch vụ riêng lẻ — một **GlobalFilter** duy nhất đủ cho toàn hệ thống.


Chi tiết triển khai structured logging, log aggregation, và distributed tracing xem Ch.11 Observability.

8.5. Case Study: KBM

Triển khai kiến trúc Gateway vào hệ thống KBM giống như quy hoạch lại luồng giao thông tại cổng chính trường đại học: tập trung kiểm soát, giám sát và điều hướng cho hàng loạt các ứng dụng phía sau.

8.5.1. Kiến trúc tổng thể

Để hiểu rõ cách cấu hình API Gateway trong thực tế, hãy xem xét kiến trúc của hệ thống KBM (8.7). Gateway hoạt động như điểm chạm duy nhất (single entry point), làm nhiệm vụ định tuyến và che giấu sự phức tạp của các dịch vụ mạng nội bộ:



Hình 8.7: Kiến trúc tổng thể KBM – Gateway là single entry point

Hệ thống KBM sở hữu hai loại gateway/router cần được phân biệt rõ:

Spring Cloud Gateway – dành cho hệ thống LMS lõi, chịu trách nhiệm định tuyến API theo đường dẫn (path), xác thực JWT, cấu hình CORS, giới hạn lưu lượng (rate limiting), và gắn mã theo dõi (correlation ID).

Go hostname-based router – router theo tên miền, viết bằng Go dành cho DevOps Lab, thực hiện định tuyến môi trường làm việc (workspace/lab runtime) dựa trên tên miền hoặc tên miền phụ (subdomain) nội bộ, đồng thời tích hợp trực tiếp với k3s/Sysbox ở lớp hạ tầng.

8.5.2. Phân tích cấu hình

Khía cạnh	Hiện trạng KBM	Giải pháp khuyến nghị	Khoảng trống
Routing	<code>lb://</code> URIs qua Eureka cho Java services; hostname routing cho DevOps Lab	✓ Đúng theo từng ranh giới	Cần tài liệu hóa quyền sở hữu route
Identity Validation	Gateway validate JWT; downstream đang lẫn header-trust và tự parse token	Edge validation + resource validation theo trust tier	Implementation drift; network enforcement chưa đủ bằng chứng
CORS	<code>allowedOrigins: ""</code>	× Nên giới hạn	Liệt kê origins cụ thể
Rate Limiting	Đã có Redis token bucket	✓ Đúng	Tinh chỉnh chính sách cho kỳ thi
SSL/TLS	Không ở gateway level	! Tùy cách triển khai	Thường terminate tại NGINX/LB
Correlation ID	Không có	! Nên thêm	GlobalFilter gắn UUID
Path Rewriting	<code>StripPrefix</code> filters	✓ Đúng	—
WebSocket	Route tới notification service	✓ Đúng	—
Health Check	Actuator endpoints	✓ Đúng	—

Bảng 8.1: Phân tích cấu hình Gateway trong KBM

8.5.3. Vấn đề không đồng nhất phiên bản JWT

Một vấn đề cần lưu ý trong KBM: Gateway sử dụng **JJWT 0.11.5** (API mới: `parserBuilder()`) trong khi các dịch vụ khác sử dụng **JJWT 0.9.1** (API cũ: `parser()`). Vấn đề không nằm ở việc resource service xác minh bằng chứng, mà ở chỗ mỗi nơi đang tự triển khai một chính sách khác nhau. Khi nâng cấp hoặc bổ sung RS256, sự sai lệch phiên bản (version mismatch) có thể khiến Gateway chấp nhận token nhưng service phía sau từ chối, hoặc nguy hiểm hơn là hai nơi kiểm tra issuer, audience và thuật toán không đồng nhất.

Không đồng nhất phiên bản thư viện JWT

Gateway sử dụng JJWT 0.11.5, trong khi các dịch vụ khác sử dụng 0.9.1. Với thuật toán khóa đối xứng đơn giản (HS256), hai phiên bản này có thể tương thích trong luồng xử lý chuẩn (happy path). Tuy nhiên, khi nâng cấp hoặc bổ sung các tính năng phức tạp (như RS256, token refresh), sự sai lệch phiên bản sẽ gây ra các lỗi tiềm ẩn khó gỡ lỗi (debug). **Lộ trình chuyển đổi (Migration path):** (1) trước mắt, đồng bộ thư viện và hợp đồng xác minh (`alg`, `iss`, `aud`, `exp`, `nbf`) để loại bỏ implementation drift; (2) chuyển sang Spring Security OAuth2 Resource Server thay cho `JwtUtil` tự viết; (3) dùng RS256/JWKS để verifier chỉ nhận public key và hỗ trợ rotation; (4) khi token ngoài không phù hợp với downstream audience, Gateway thực hiện token exchange sang internal token có chữ ký thay vì thay thế bằng plain headers.

8.5.4. Đề xuất migration

Giai đoạn 1 — Tăng cường bảo mật (ưu tiên cao, chi phí triển khai thấp):

- Hạn chế chặt chẽ CORS origins (liệt kê các frontend URL cụ thể)
- Gỡ bỏ mọi `X-User-*` do client gửi, giữ `Authorization` cho tới khi có signed downstream token thay thế
- Thống nhất thư viện và hợp đồng kiểm tra `alg` /issuer/audience/expiry/not-before
- Xác minh bằng cấu hình triển khai rằng chỉ Gateway và workload được cấp phép môi gọi được service nội bộ
- Tài liệu hóa ranh giới (boundary) giữa Spring Cloud Gateway và Go hostname router

Giai đoạn 2 — Observability (ưu tiên trung bình):

- Thêm `X-Correlation-Id` GlobalFilter
- Request/response logging tại Gateway

Giai đoạn 3 — Bảo vệ và phân tầng tin cậy (ưu tiên trung bình):

- Tinh chỉnh chính sách rate limiting hiện có cho contest mode (per-route limit riêng cho `/submissions/**`)
- Giới hạn kích thước payload cho các endpoint tải tệp lên (file upload)
- Chuyển sang RS256/JWKS và signed identity propagation đúng audience; bổ sung workload identity/mTLS cho luồng nhạy cảm

⚠ Sai lầm thường gặp

Đưa business logic vào Gateway

Nếu Gateway thực hiện biến đổi dữ liệu (data transformation), kiểm tra quy tắc hợp lệ (validation rules), hoặc điều phối các lời gọi (orchestrate calls) giữa các dịch vụ — hậu quả: Gateway sẽ biến thành một monolith mới — mọi thay đổi về business logic đều đòi hỏi phải triển khai (deploy) lại toàn bộ hệ thống Gateway. **Phòng tránh:** Gateway chỉ nên đảm nhiệm xử lý các cross-cutting concerns (auth, CORS, routing, rate limiting). Business logic thuộc về các services.

Mỗi service tự xác minh JWT theo một cách khác nhau

Nếu mỗi dịch vụ dùng một phiên bản thư viện, tập thuật toán và quy tắc issuer/audience riêng, hệ thống sẽ xuất hiện lỗi hỏng không đồng nhất dù cùng mang tên “JWT validation”. **Giải pháp phòng tránh:** Gateway xác thực ở biên; resource service xác minh signed proof bằng cấu hình hoặc middleware chuẩn hóa; mọi service thực hiện local authorization. Không thay verification bằng việc tin một plain header chỉ vì request đến từ mạng nội bộ.

Không có phương án dự phòng (fallback) khi Gateway ngừng hoạt động (SPOF)

Gateway là điểm vào duy nhất (single point of entry) cũng đồng nghĩa là điểm lỗi duy nhất (single point of failure). Hậu quả: Khi Gateway gặp sự cố (crash), **toàn bộ** hệ thống sẽ trở nên gián đoạn và không thể truy cập (unreachable). **Giải pháp phòng tránh:** triển khai Gateway theo mô hình Tính sẵn sàng cao (High Availability - HA) bằng cách chạy nhiều instances sau một Load Balancer (ví dụ: NGINX/ALB). Đồng thời, Gateway không được phép gặp lỗi dây chuyền (Cascading Failure): Nếu hệ thống Redis (sử dụng cho cơ chế Rate Limiting) gặp sự cố ngừng hoạt động, Gateway cần được trang bị Circuit Breaker để cho phép lưu lượng truy cập tiếp tục đi qua (pass-through traffic) thay vì làm đình trệ toàn bộ hệ thống. Ở phía Client, phải triển khai cơ chế Exponential Backoff khi nhận HTTP 429.

CORS allowAll trong production

Cho phép mọi nguồn gốc (origin) đọc phản hồi API — chính sách quá rộng nếu API không chủ đích phục vụ public cross-origin. Cần phân biệt hai chuyện: với chế độ gửi kèm credentials, trình duyệt vốn đã từ chối tổ hợp wildcard * + credentials, nên muốn xác thực bằng cookie hoạt động xuyên origin thì bắt buộc phải allowlist origin cụ thể; còn CSRF là mối đe dọa riêng, không do CORS xử lý. **Giải pháp phòng tránh:** Liệt kê rõ ràng các nguồn gốc hợp lệ, và với xác thực dựa trên cookie phải bổ sung SameSite, CSRF token hoặc kiểm tra Origin (Ch.9).

Bổ sung bảo vệ tại Gateway: Sau khi xử lý các sai lầm trên, cần thêm các lớp bảo vệ sau:

- **JWKS (JSON Web Key Set):** Gateway không hardcode Public Key tĩnh để giải mã JWT. Thay vào đó, tự động lấy (fetch) từ endpoint `/.well-known/jwks.json` của Auth Service để cho phép xoay vòng khóa (key rotation) định kỳ, kết hợp cùng bộ đệm nội bộ (In-memory Cache) nhằm giảm tải I/O.
- **Redis Blacklist:** Gateway xác thực JWT stateless, nên cần tích hợp Redis Blacklist để chặn token đã bị thu hồi (ví dụ: sinh viên bị đình chỉ). Để tránh lỗi dây chuyền nếu Redis gặp sự cố, Gateway cần trang bị Fallback/Circuit Breaker.
- **Giới hạn kích thước (Payload Size Limit):** Áp dụng giới hạn cứng để chặn tấn công DoS hoặc payload quá lớn trước khi forward request.
- **HttpOnly Cookie ở biên:** Khi Gateway hoạt động như BFF, giữ token trong *HttpOnly Cookie* thay vì đưa Bearer token cho JavaScript; Gateway chuyển cookie thành credential nội bộ khi route và vẫn áp dụng biện pháp chống CSRF phù hợp (Ch.9).

 Interactive Demo

Xem minh họa động tại companion web:

Cơ chế định tuyến của API Gateway – – api-gateway-routing.html

Service Discovery & Registry – – service-discovery.html

8.6. Tổng kết

API Gateway giải quyết một trong những thách thức cơ bản nhất khi client tương tác với hệ thống microservices: thay vì phải biết địa chỉ của từng service, client chỉ cần biết một endpoint duy nhất. Gateway đảm nhận routing, edge authentication, CORS và các cross-cutting concerns; service phía sau tập trung vào business logic nhưng vẫn sở hữu local authorization và xác minh signed proof theo trust tier.

Spring Cloud Gateway (WebFlux) là lựa chọn hiện đại cho hệ sinh thái Java — reactive, non-blocking, tích hợp sâu với Spring Cloud (Eureka, Circuit Breaker). Cấu hình định tuyến (route configuration) với `lb://` URIs kết hợp tự động với service discovery và load balancing. Nhờ đó, các services có thể mở rộng (scale) mà không cần thay đổi cấu hình tại Gateway.

Tập trung xử lý các cross-cutting concerns tại Gateway — như kiểm tra token ở biên, CORS, rate limiting, correlation ID — là khoản đầu tư giúp hệ thống dễ bảo vệ, debug và vận hành hơn. Nguyên tắc cốt lõi: Gateway kiểm soát ingress; signed proof đi qua trust boundary; service đích kiểm tra bằng chứng và quyết định authorization cho nghiệp vụ mình sở hữu.

Phân tích hệ thống KBM cho thấy cấu trúc Gateway cơ bản là phù hợp (Spring Cloud Gateway + Eureka + JWT + rate limiting Redis cho LMS core, Go hostname router cho DevOps Lab), nhưng CORS còn mở rộng ở một số môi trường và identity propagation chưa thống nhất: header-trust, HS256 shared secret và nhiều phiên bản thư viện đang cùng tồn tại. Lộ trình chuyển đổi ưu tiên làm sạch request ở biên (ingress sanitation) và một hợp đồng xác minh chung, tiếp đến RS256/JWKS cùng signed downstream identity, rồi bổ sung workload identity cho các trust tier nhạy cảm.

Ở Chương 9, chúng ta sẽ tìm hiểu sâu về **bảo mật microservices** — JWT structure, OAuth2 integration, chiến lược dual-secret key rotation, và RBAC trong KBM.

8.7. Đọc thêm

Sách tham khảo chính:

- [2a] Chris Richardson, *Microservices Patterns*, 1st Ed. — Ch.8: External API Patterns (API Gateway, BFF)
- [4a] Sam Newman, *Building Microservices* — Ch.4: Integration, Smart Endpoints and Dumb Pipes
- [1] Thomas Erl, *SOA Analysis & Design* — API Gateway trong enterprise SOA context

Sách bổ trợ:

- [2b] Chris Richardson, *Microservices Patterns*, 2nd Ed. — Ch.8: External API Patterns (updated)
- [5] Hugo Rocha, *Practical Event-Driven MS Architecture* — Ch.9: UI in EDA, BFF pattern

Nguồn trực tuyến:

- Spring Cloud Gateway reference — docs.spring.io/spring-cloud-gateway
- Netflix Zuul → Spring Cloud Gateway migration guide
- OWASP API Security Top 10 — owasp.org/www-project-api-security
- NIST SP 800-207 — Zero Trust Architecture
- RFC 8725 và RFC 9068 — JWT Best Current Practices và JWT Access Token Profile

Bài tập: Xem Phụ lục Bài tập để luyện tập:

8-0 – Ôn tập: API Gateway Cross-cutting Concerns ([L1])

8-1 – Case Study: Netflix Zuul 1 → Zuul 2, và Spring Cloud Gateway ([L2])

8-2 – ADR: Rate Limiting Strategy (Architecture Decision Record [L2])

Tài liệu tham khảo

- Richardson, C. (2018). *Microservices Patterns: With examples in Java*, 1st Edition. Manning Publications.
- Richardson, C. (2025). *Microservices Patterns: With examples in Java*, 2nd Edition (bản MEAP đang cập nhật; nội dung trích dẫn truy cập 07/2026). Manning Publications.